

Mouhamed MBAYE

Ingénieur en TAL

Montpellier, France (Mobile)

mouhamedmbaye371@gmail.com | +33 7 64 28 43 88

[linkedin.com/in/mouhamed-mbaye-nlp-tal](https://www.linkedin.com/in/mouhamed-mbaye-nlp-tal) | <https://m-mbaye30.github.io>

PROFIL

Spécialisé en Traitement Automatique des Langues (TAL), je suis titulaire d'une licence en linguistique et de deux Masters en TAL. J'ai acquis une expérience concrète en extraction d'information et en collaboration interdisciplinaire au sein d'un laboratoire **IMGT**, CNRS. Maîtrise de Python, traitement de données multilingues (français, anglais, arabe).

COMPÉTENCES TECHNIQUES

NLP & IA Générative Hugging Face, LLMs, Prompt Engineering, RAG, IA Agentique SpaCy, NLTK, vLLM, Ollama, LangChain, LangGraph.

ML & Deep Learning Python, Scikit-learn, PyTorch, Pandas, NumPy, Régression, Classification, Clustering, Fine-Tuning.

MLOps & Cloud Docker, FastAPI, Flask, GCP (Google Cloud Platform), CI/CD, Git/GitHub.

Bases de Données SQL, MySQL, MongoDB, ChromaDB, SPARQL, RDF, OWL, Neo4j.

EXPÉRIENCES PROFESSIONNELLES

Ingénieur NLP Janvier – Juillet 2025
IMGT (IGH, CNRS), Montpellier

- Conception et mise en production d'une solution d'extraction d'information à partir des textes scientifiques.
- Développement de pipelines ETL pour le prétraitement de données non structurées.
- Entraînement et optimisation de modèles **BERT**, **BiLSTM-CRF**, **GLiNER** avec analyse comparative performance/coût.
- Création d'interfaces interactives avec **Streamlit** pour l'exploitation des résultats par les experts métier.

Data Scientist-NLP Janvier – Juin 2024
Université Mohammed V, Rabat

- Modélisation et classification automatique de documents via des architectures de type **transformers** comme **BERT**.
- Constitution, nettoyage et annotation de datasets d'entraînement.
- Évaluation rigoureuse des modèles pour garantir la fiabilité des prédictions en environnement réel.

PROJETS

MedicalGraphEmbedd | *Python, Transformers (CamemBERT), spaCy, UMLS API, Neo4j*

- Pipeline NLP bout-en-bout : classification de documents cliniques, extraction d'entités nommées (NER) par CamemBERT fine-tuné, puis enrichissement sémantique automatique via l'API UMLS.
- Construction d'un graphe de connaissances médical à partir des entités enrichies (CUI, SNOMED-CT), avec normalisation lexicale et liaison sémantique par similarité vectorielle.

Système RAG (KNOW-SN) | *Python, FastAPI, Docker, GCP, ChromaDB, LangChain*

- Architecture de recherche vectorielle optimisée sur plus de 600 documents avec pipeline de **reranking intelligent**.
- Implémentation de mesures de sécurité contre les injections de prompt.

Orchestrateur d'IA Agentique | *Python, Streamlit, Google Gemini API, GCP*

- Système multi-agents coordonné pour transformer des documents non structurés en rapports structurés via l'API Gemini.

RecSys d'Orientation Intelligente | *FastAPI, GCP, PostgreSQL (pgvector), Sentence-Transformers*

- Système de recommandation académique basé sur la **recherche sémantique** et un scoring hybride.

FORMATION

Master 2 Traitement automatique des langues (TAL NLP) Université Marie & Louis Pasteur, Besançon, France	Juin 2025
Licence Linguistique Université Cady Ayyad, Marrakech, Maroc	Juin 2024

CERTIFICATIONS

Natural Language Processing with Probabilistic Models <i>DeepLearning.AI – 2024</i> — Maîtrise des modèles probabilistes, incluant les N-grammes, l’étiquetage de séquences et les algorithmes d’auto-complétion.
Natural Language Processing with Classification and Vector Spaces <i>DeepLearning.AI – 2024</i> — Techniques fondamentales du TAL : analyse de sentiment, espaces vectoriels et plongements de mots (<i>word embeddings</i>).
Retrieval Augmented Generation (RAG) <i>DeepLearning.AI – 2025</i> — Conception, implémentation et déploiement de systèmes RAG complets et fiables, adaptés aux domaines d’application spécifiques.
Text Mining for Marketing <i>O.P. Jindal Global University – 2025</i> — Acquisition des bases du <i>Text Mining</i> et identification des meilleures pratiques en analyse textuelle pour la prise de décision.
Elements of AI <i>University of Helsinki & MinnaLearn – 2024</i> — Compréhension fondamentale des concepts de l’IA : machine learning, réseaux de neurones et implications sociétales.

LANGUES

Français : Courant
Anglais : Avancé
Arabe : Courant
Wolof : Maternelle