

Présentation de rapport de stage Master II

Sujet :

**Extraction automatique d'entités nommées dans les descriptions INN
des anticorps monoclonaux**

Réalisé par :

Mouhamed MBAYE

Tutrice :

Pr Iana ATANASSOVA

Encadré par :

Dr Patrice DUROUX

Dr Gaoussou SANOU

Dr Taciana MANSO

Structure d'accueil : **IMGT®**

Durée de stage : 6 mois

Année universitaire :

2024/2025



Remerciements

Je tiens à remercier mes encadrants **Iana ATANASSOVA**, **Patrice DUROUX**, **Gaoussou SANOU** et **Taciana MANSO**, pour leurs confiances, leur soutien et leurs conseils durant tout au long de cette expérience. Leurs expertises et leurs patiences m'ont été d'une grande aide pour atteindre les objectifs du stage.

Je remercie également **Madame Sofia KOSSIDA** de m'avoir offert cette opportunité de stage au sein d'une équipe dynamique et interdisciplinaire.

Un très grand merci à toute l'équipe d'IMGT pour leur accueil chaleureux, leur esprit d'équipe, et surtout leur bonne humeur durant tout mon stage.

Table des matières

Remerciements.....	1
RÉSUMÉ	4
I. INTRODUCTION.....	5
II. Chapitre 1 : Revue Bibliographique	7
1. Introduction.....	7
2. Concepts fondamentaux	7
2.1. Reconnaissance d'entités nommées (NER).....	7
2.2. Les anticorps monoclonaux thérapeutiques (mAbs)	7
3. Les approches de TAL utilisées en NER et leur évolution historique	8
3.1. Approches basées sur des règles (1960)	8
3.2. Approches d'apprentissage automatique classique (2000)	8
3.3. Approches d'apprentissage profond (2010).....	9
3.4. Modèles basés sur les Transformers (2017)	9
3.5. Les approches basées sur les LLM	10
4. Ressources et outils en BioNER.....	10
5. Conclusion	10
III. Chapitre 2 : Méthodologie	12
1. Introduction.....	12
2. IMGT-NER.....	12
2.1. Évaluation initiale et limitations identifiées	12
3. Corpus et annotation	13
3.1. Description du corpus	13
3.2. Annotation du corpus	13
4. Revue des modèles entraînés	14
4.1. Les modèles scispaCy.....	14
4.2. Le modèle BiLSTM-CRF	14
4.3. Le modèle GLiNER	15
4.4. Le modèle BERT	16
5. Conclusion	17
IV. Chapitre 3 : Analyse comparative des modèles.....	18
1. Introduction.....	18

2.	Description du jeu de données et méthodologie d'évaluation.....	18
3.	Métriques d'évaluation utilisées	18
4.	Résultats	19
4.1.	Résultats des modèles ScispaCy.....	19
4.2.	Résultats du modèle GLiNER.....	21
4.3.	Résultats du modèle BiLSTM-CRF	22
4.4.	Résultats du modèle BERT	22
4.5.	Synthèse globale des résultats.....	22
5.	Conclusion	24
V.	Chapitre 4 : Développement de l'interface Utilisateur et Déploiement	25
1.	Introduction.....	25
2.	Fonctionnalités de l'interface utilisateur.....	25
3.	Déploiement de l'application.....	26
4.	Conclusion	27
VI.	CONCLUSION	28
VII.	Références.....	29
VIII.	Liste des figures	31
IX.	Liste des tableaux	31

ABSTRACT

In this report, we present our final year work at IMGT. This work concerns the design of a named entity recognition model for INN descriptions of therapeutic monoclonal antibodies. Faced with the limitations of a rule-based model (lack of robustness and rigidity, costly maintenance), several models were tested, trained, fine-tuned and evaluated on a jeu de données of 1306 INN descriptions of antibodies containing 21,844 for 18 categories/labels. Models tested included ScispaCy variants, a classic BiLSTM-Crf model, two GLiNER and BERT Transformer models, all trained on 900 descriptions and tested on 406. The BiLSTM-Crf model performed best overall, with an F1-Score of 0.92%, significantly outperforming the BERT model 0.84% and GLiNER 0.83%. The scispaCy variants performed less well (between 0.69% and 0.72% F1-score). The best models have been integrated into a user interface (UI) developed with Streamlit for greater convenience and interactivity. The application was deployed to give access to the whole team.

RÉSUMÉ

Nous présentons dans ce rapport notre travail de fin d'études au sein d'IMGT. Ce travail porte sur la conception d'un modèle de reconnaissance d'entités nommées dans le domaine de l'immunogénétique. Ce modèle a pour tâche d'extraire les entités clés dans les descriptions des anticorps monoclonaux thérapeutiques contenues dans des documents INN (International Nonproprietary Names). Face aux limitations des modèles à base de règle (manque de robustesse et de rigidité, maintenance coûteuse), plusieurs modèles ont été expérimentés, entraînés, affinés et évalués sur un jeu de données de 1306 descriptions INN d'anticorps contenant 21, 844 pour 18 catégorie/labels. Parmi ces modèles, nous avons des variantes de ScispaCy (en_ner_bionlp13cg_md, en_ner_bc5cdr_md, en_core_sci_lg, en_core_sci_scibert), un modèle classique BiLSTM-Crf, deux modèles de Transformers GLiNER et BERT, entraînés tous sur 900 descriptions et testés sur 406. Le modèles BiLSTM-Crf a obtenu la meilleure performance dans l'ensemble, avec un F1-Score de 0.92% surpassant significativement le modèle de BERT 0.84% et GLiNER 0.83%. Les variantes de scispaCy ont obtenu des performances inférieures (entre 0.69% ET 0.72% de F1-score). Les meilleurs modèles ont été intégrés dans une interface utilisateur (UI) développée avec Streamlit pour une meilleure utilisation pratique et interactive. L'application a été déployée pour donner l'accès à toute l'équipe.

I. INTRODUCTION

Dans l'ère de l'intelligence artificiel (IA), caractérisée par l'explosion des données et d'outils intelligents, l'extraction automatique d'information dans les documents scientifiques reste un défi pour les chercheurs(es), surtout dans un contexte où les publications scientifiques ainsi que les bases de données spécialisées sont en pleine extension, rendant le traitement manuel des données de plus en plus laborieux et chronophage.

Ce stage s'est déroulé à IMGT® (the international ImMunoGeneTics information system®), un système d'information internationale spécialisé en immunogénétique. Fondé en 1989 à Montpellier, sous tutelle de l'Université de Montpellier et du CNRS, IMGT® s'est imposé comme la référence mondiale dans son domaine. Sa mission principale d'assurer la collecte, le stockage, le traitement expertisé, la transmission, l'archivage et la traçabilité des données relatives aux immunoglobulines (IG ou anticorps), aux récepteurs des cellules T (TR) et à d'autres protéines du système immunitaire, tant chez l'homme que chez d'autres vertébrés. Pour cela, IMGT a mis en place au fil des années plusieurs bases de données spécialisées dédiées aux IG, TR ainsi qu'aux anticorps monoclonaux thérapeutiques (IMGT/mAb-DB).

La base de données IMGT/mAb-DB, ainsi que sa version sémantique IMGT/mAb-KG, constituent des ressources essentielles pour la recherche sur les anticorps monoclonaux thérapeutiques (mAbs). Actuellement, leur alimentation repose sur un processus manuel et chronophage d'extraction d'informations à partir de sources hétérogènes, dont des documents non structurés comme les listes de Dénominations Communes Internationales (DCI, ou INN en anglais), publiées par l'Organisation Mondiale de la Santé (OMS), et des ressources structurées telles que le thésaurus du National Cancer Institute (NCIT). Face à l'augmentation constante du volume de données et à la nécessité d'accélérer le développement des mAbs, l'automatisation de ce processus d'alimentation est devenue un impératif.

L'objectif principal de ce stage est donc l'exploration et la mise en place d'une approche de Traitement Automatique des langues (TAL) pour automatiser l'extraction des entités d'intérêts dans les descriptions des mAbs, à partir de ces diverses sources afin de faciliter leur intégration dans IMGT/mAb-DB et IMGT/mAb-KG.

Pour aborder cette problématique et atteindre les objectifs fixés, une méthodologie structurée a été adoptée. Dans un premier temps, nous avons fait une revue de la littérature scientifique pour identifier les différentes approches pertinentes pour la reconnaissance d'entités nommées, en particulier dans le domaine biomédical. Par la suite, un corpus constitué de définitions de mAbs issues des documents INN, a été assemblé. Ce corpus a fait l'objet d'un processus d'annotation rigoureux, initié par une phase de pré-annotation automatique à l'aide des techniques de Patterns Matching de la librairie spaCy¹, suivie d'une correction et d'une validation manuelles avec une experte du domaine via l'outil d'annotation Label Studio².

Une fois le corpus préparé, plusieurs modèles d'apprentissage automatique ont été entraînés et évalués. Ces modèles incluent différentes variantes de la librairie scispaCy (Neumann et al.,

¹ [Rule-based matching · spaCy Usage Documentation](#)

² [Label Studio — Data Labeling](#)

2019)³ (en_ner_bionlp13cg_md, en_ner_bc5cdr_md, en_core_sci_lg, en_core_sci_scibert), un modèle BiLSTM-CRF(Huang et al., 2015)⁴, une approche basée sur les modèles à base d'architecture de “transformer” tels que GLiNER(Zaratiana et al., 2023)⁵ et BERT(Devlin et al., 2019)⁶. Les performances de chaque modèle ont été mesurées à l'aide de métriques standards utilisées en NER (un sous domaine du traitement automatique des langues qui vise à identifier et classer automatiquement des mentions d'entités dans un texte) telles que la précision, le rappel et le F1-score. Enfin, les modèles les plus performants (Gliner, BiLSTM-CRF, et en_core_sci_lg) ont été intégrés dans une interface utilisateur développée avec Streamlit, permettant une démonstration interactive de l'extraction d'entités. Des travaux ont également été initiés en vue du déploiement de cette application.

Le présent rapport est organisé de la manière suivante : le premier chapitre dressera un état de l'art des différentes méthodes existantes pour la NER les concepts de base. Le second chapitre présentera la méthodologie déployée depuis la constitution du corpus et le processus d'annotation jusqu'à la description des différents modèles explorés. Le troisième chapitre consistera à présenter et à comparer les résultats de chaque modèle. Le quatrième chapitre abordera les aspects liés au déploiement de l'interface utilisateur avec Streamlit. Une conclusion générale permettra de déterminer les travaux réalisés et les perspectives.

³ <https://arxiv.org/abs/1902.07669>

⁴ <https://arxiv.org/abs/1508.01991>

⁵ <https://ar5iv.labs.arxiv.org/html/2311.08526>

⁶ <https://arxiv.org/abs/1810.04805>

II. Chapitre 1 : Revue Bibliographique

1. Introduction

Le domaine de l'immunologie génère aujourd'hui beaucoup de données textuelles non structurées, issues de publications scientifiques, de rapports d'essais cliniques ou de dossiers médicaux électroniques. L'extraction d'informations dans ces documents constitue un défi majeur pour accélérer la recherche scientifique et les processus de développement de produits et médicaments.

La Reconnaissance d'Entités Nommées ("Named Entity Recognition en anglais), permet d'identifier automatiquement des mentions d'entités dans les textes. Nous présentons dans ce chapitre une revue bibliographique des différentes approches de Traitement Automatique des Langues utilisées pour la reconnaissance d'entités nommées, ainsi que les défis liés au domaine biomédicale (BioNER).

2. Concepts fondamentaux

2.1.Reconnaissance d'entités nommées (NER)

La NER est un sous-domaine du Traitement automatique des langues qui vise à identifier et à classifier des jetons (ou 'tokens' en anglais) en catégories prédéfinies d'entités. Initialement conçue pour reconnaître des entités génériques (noms propres, lieux, dates, etc.), la NER s'est progressivement étendue à d'autres types d'entités dans les domaines spécialisés, notamment dans le domaine biomédical où elle permet d'identifier des gènes, des protéines, des maladies, etc. Elle est particulièrement complexe en raison de l'ambiguïté inhérente liée aux langues naturelles.

2.2.Les anticorps monoclonaux thérapeutiques (mAbs)

Les anticorps monoclonaux (mAbs) sont des protéines synthétiques conçues pour imiter les anticorps naturels du système immunitaire. Ils ciblent des molécules spécifiques et sont largement utilisés dans le traitement de maladies comme le cancer et les maladies auto-immunes.




Figure 1: la structure d'un anticorps⁷

On distingue les chaînes lourdes (en bleu) constituées de quatre domaines : une région variable (VH) dans la partie supérieure et trois régions constantes (CH1, CH2 et CH3) dans la partie inférieure. Les

⁷[IMGT Education](#)

chaînes légères (en vert) comprennent deux domaines : une région variable (VL) située en haut et une région constante (CL) en dessous.

3. Les approches de TAL utilisées en NER et leur évolution historique

La reconnaissance d'entités nommées a connu une importante évolution durant ces trois dernières décennies, passant des approches à base de règles aux approches intelligentes et très sophistiquées, capables de traiter des gros volumes de textes, et cela reflète un progrès très majeur réalisé dans le domaine du TAL.

3.1.Approches basées sur des règles (1960)

Les premiers systèmes de NER sont apparus dans les années 1960. Ces systèmes utilisent des règles linguistiques, souvent combinées à des dictionnaires ou des lexiques spécialisés (gazetteers), pour identifier les entités (Eftimov et al., 2017). Par exemple, Borkowski et Watson ont développé en 1967 un algorithme basé sur des règles et des marqueurs lexicaux (comme capitalisation) pour détecter automatiquement les noms d'entreprises.

Avantages et limitations : Malgré leur ancienneté, les systèmes basés sur des règles ont plusieurs avantages, comme l'interprétabilité, la capacité à atteindre une bonne précision dans des domaines spécifiques avec une terminologie bien définie. En plus, ils ne nécessitent pas beaucoup de données annotées pour leur développement initial. Cependant, leur conception et leur maintenance sont coûteuses et ils manquent de robustesse et d'adaptabilité face aux variations linguistiques, aux erreurs typographiques ou aux nouveaux termes non prévus par les règles. Leur couverture est également limitée, rendant presque impossible la création de règles exhaustives pour couvrir toutes les variations possibles. Malgré ces limitations, ces approches sont parfois utilisées en complément d'autres méthodes, notamment pour traiter des cas spécifiques ou pour intégrer des connaissances.

3.2.Approches d'apprentissage automatique classique (2000)

Au début des années 2000, l'émergence des techniques d'apprentissage automatique a marqué un tournant majeur pour la reconnaissance d'entités nommées. Ces approches considèrent la NER comme un problème d'étiquetage de séquences et utilisent des algorithmes pré-entraînés sur des corpus de textes annotés pour apprendre à prédire l'étiquette de chaque mot dans une phrase. Plusieurs algorithmes ont été mis en place comme les modèles de Markov Cachés (HMM - Hidden Markov Models), qui sont des modèles probabilistes génératifs qui modélisent la probabilité conjointe de la séquence de mots et de la séquence d'étiquettes, et les modèles de machines à Vecteurs de Support (SVM - Support Vector Machines), des "classifieurs" discriminatifs qui cherchent à trouver un hyperplan optimal séparant les différentes classes d'étiquettes dans un espace de caractéristiques.

Champs Aléatoires Conditionnels (CRF - Conditional Random Fields) sont des modèles probabilistes discriminatifs particulièrement adaptés à l'étiquetage de séquences. Contrairement aux HMM, les CRF modélisent directement la probabilité conditionnelle de la séquence d'étiquettes étant donnée la séquence de mots, ce qui leur permet de prendre en compte des dépendances complexes entre les caractéristiques sans faire d'hypothèses d'indépendance fortes (Lafferty et al., 2001).

Avantages et limitations : Les systèmes d'apprentissage automatique présentent plusieurs avantages et limitations. Parmi les avantages, leur capacité à s'adapter à des données non vues pendant l'entraînement, de plus, ils sont moins sensibles aux variations que les systèmes basés sur des règles. Cependant, ces systèmes ont aussi des limitations, car ils dépendent fortement des données annotées, dont la création est coûteuse, et l'ingénierie de caractéristiques est complexe, et la performance des modèles dépend fortement de la qualité et de la pertinence des caractéristiques conçues manuellement. De plus, ils peinent à capturer les longues dépendances, ce qui rend difficile l'exploitation du contexte global de la phrase.

3.3.Approches d'apprentissage profond (2010)

L'introduction de l'apprentissage profond (Deep Learning) au début des années 2010 a révolutionné la reconnaissance d'entités nommées, comme de nombreux autres domaines du traitement automatique des langues. Les modèles de Deep Learning ont permis de s'affranchir en grande partie le features engineering en apprenant automatiquement vers des représentations vectorielles (embedding) denses et contextuelles des mots et des séquences. Les architectures clés incluent : les Réseaux de Neurones Convolutifs (CNN - Convolutional Neural Networks), utilisés pour extraire des caractéristiques locales au niveau des caractères ou des mots, etc Réseaux de Neurones Récurrents (RNN - Recurrent Neural Networks), capables de modéliser des séquences en tenant compte de l'ordre des mots (Lample et al., 2016a). Les variantes comme les LSTM (Long Short-Term Memory) et les GRU (Gated Recurrent Units) ont été développées pour mieux capturer les dépendances à longue distance en gérant les problèmes de disparition ou d'explosion du gradient.

Avantages et limitations : L'avantage de ces modèles réside dans leur capacité à apprendre automatiquement des représentations pertinentes directement à partir des données. Ils permettent de modéliser les dépendances séquentielles en capturant le contexte. Cependant, ils nécessitent de grandes quantités de données annotées et de grandes ressources.

3.4.Modèles basés sur les Transformers (2017)

Depuis 2018, l'architecture Transformer et les modèles de langage pré-entraînés basés sur celle-ci, ont établi de nouveaux records de performance pour les tâches de NER et de nombreuses autres tâches du TAL (Vaswani et al., 2017). Les Transformers reposent sur des mécanismes d'auto-attention (self-attention) qui permettent au modèle de pondérer l'importance des différents mots dans la séquence d'entrée lors de l'encodage de chaque mot. Cela permet de capturer efficacement les dépendances contextuelles, comprendre la sémantique des phrases, et facilite la parallélisation de l'entraînement.

Avantages et limitations : Les Transformers présentent plusieurs avantages et limitations. Parmi les avantages, l'apprentissage par transfert efficace, où le pré-entraînement sur de grands corpus permet d'obtenir de bons résultats même avec peu de données. De plus, ils offrent des représentations contextuelles riches, capturant finement les nuances sémantiques et les dépendances contextuelles. Cependant, les limitations résident dans leur coût de pré-entraînement très élevé, nécessitant d'importantes quantités de données et de ressources computationnelles. En outre, la taille des modèles est souvent très volumineuse, et

l'interprétabilité reste limitée, rendant la compréhension du fonctionnement interne des Transformers un défi.

3.5. Les approches basées sur les LLM

Les grands modèles de langage, ou Large Language Model (LLMs) en anglais, sont des modèles probabilistes entraînés pour la prédiction et la génération des séquences de tokens. Contrairement aux modèles de NER traditionnels qui nécessitent une préparation de données spécifique et avancée, notamment dans les domaines spécialisés comme immunogénétique, les LLMs sont directement exploitables via le « prompting ». Pour adapter les LLMs à la tâche de NER, diverses approches ont été proposées, parmi ces approches :

La NER comme une génération de texte : pour certains LLMs, la NER est une tâche de génération de texte, où le modèle génère du texte en indiquant explicitement les entités et leur label. C'est une approche parfaitement exploitée par les LLMs car c'est leur objectif premier (Keraghel et al., 2024).

Avantage et limitation : Les avantages d'utilisations des LLMs pour la NER résident dans leur flexibilité, leur adaptabilité rapide grâce aux prompts. Malgré ça, ils présentent des limitations, comme le manque de spécialisation, la variabilité des résultats, le coût computationnel élevé ainsi que les erreurs liées à l'hallucination.

4. Ressources et outils en BioNER

Le domaine biomédical présente plusieurs défis particuliers tels que la terminologie complexe et spécialisée, les entités imbriquées et discontinues, le manque de données annotées, rendant la NER plus complexe que dans les domaines non spécifiques. Pour faire face à ces défis, plusieurs ressources ont été développées, comme :

- NCBI Disease Corpus, qui contient environ 6 900 phrases annotées avec des mentions de maladies, extraites de résumés PubMed.
- BC5CDR, un Corpus de la BioCreative V Chemical Disease Relation task, avec environ 1 500 résumés PubMed annotés pour les mentions de produits chimiques et de maladies.
- JNLPBA, un Corpus de la Joint Workshop on Natural Language Processing in Biomedicine and its Applications, avec environ 2 000 résumés annotés pour les gènes/protéines, l'ADN, l'ARN, les lignées cellulaires et les types cellulaires.

Concernant les outils et plateformes spécifiques, nous pouvons citer : PubTator, un système d'annotation automatique de la littérature biomédicale pour les gènes, maladies, produits chimiques, mutations et espèces ; et MetaMap, un outil développé par la National Library of Medicine pour mapper les termes biomédicaux aux concepts UMLS.

5. Conclusion

Dans ce premier chapitre, nous avons exploré l'état de l'art des approches NER, en partant sur des concepts fondamentaux jusqu'aux outils spécifiques de BioNER. L'évolution historique des approches NER montre une transition des méthodes basées sur des règles vers d'architectures

complexes d'apprentissage profond actuelles, chaque avancée est une amélioration sur la précision et la robustesse des systèmes.

III. Chapitre 2 : Méthodologie

1. Introduction

Nous présentons dans ce chapitre la méthodologie adoptée pour répondre à notre problématique. Nous commencerons par présenter IMGT-NER, un modèle de reconnaissance d'entités nommées basé sur des règles, développé dans la phase initiale de ce projet. Ensuite, nous détaillons le processus d'annotation mis en œuvre pour obtenir un jeu de données de qualité pour l'entraînement et l'évaluation des modèles. Enfin, nous exposons l'architecture de différents modèles choisis après une revue bibliographique afin de proposer une alternative pour IMGT-NER. Cette démarche méthodologique nous permet d'évaluer de manière systématique les solutions existantes tout en explorant des pistes d'amélioration innovantes.

2. IMGT-NER

IMGT-NER est un modèle de reconnaissance d'entités nommées développé antérieurement dans le cadre de ce projet. Il repose initialement sur une approche basée sur les règles, définies manuellement à partir de patrons lexico-syntaxiques spécifiques aux entités ciblées. Techniquement, son implémentation repose sur le modèle de base « **en_core_sci_sm** » de ScispaCy, une version de la bibliothèque spaCy spécialisée dans le traitement des textes scientifiques.

2.1. Évaluation initiale et limitations identifiées

L'analyse des performances présentée dans (*Rapport Stage M2 DASSOU SIKI*, 2022) a porté sur quarts descriptions de mAbs issues des listes DCI (119 à 127), évaluées selon les métriques standard utilisées dans la reconnaissance d'entités nommées : la précision, le rappel et le F-score. Bien qu'une efficacité apparente sur des cas spécifiques, des limitations importantes de cette approche ont été identifiées, tels que la faible généralisation et de robustesse, une maintenance coûteuse et un manque de flexibilité.

Ces limitations ont fortement motivé la réorientation du projet vers l'exploration des nouvelles approches plus robustes basées sur l'apprentissage automatique, capables de d'appréhender des représentations contextuelles complexes pour améliorer significativement la précision. Cette transition méthodologique répond à un double objectif : surmonter les contraintes du système à base de règle tout en maintenant une précision élevée dans la prédiction.

mAb	Nombre d'entités reconnues	Nombre d'entités correctement reconnues	Nombre d'entités Correctes non reconnues
Test sur liste 125			
adintrevimab	70	67	3
bafisontamab	111	111	12
fidasintamab	130	128	10
ligufalimab	74	73	1
zamerovimab	68	68	2
Test sur liste 119			
abelacimab	74	73	3
birtamimab	64	62	5
Test sur liste 127			
anvatabart opa-dotin	74	73	3
boserolimab	74	71	2

Tableau 1: Résultat d'évaluation d'IMGT-NER

3. Corpus et annotation

3.1. Description du corpus

Pour mettre en place un système de NER basé sur l'apprentissage automatique, nous avons constitué un corpus de description des mAbs. Ces descriptions proviennent des listes de Dénominations Communes Internationales (DCI) des substances pharmaceutiques, ou International Nonproprietary Names (INN) en anglais, établies par l'Organisation Mondiale de la Santé (OMS) qui a la responsabilité constitutionnelle d'établir des normes internationales pour les produits biologiques, pharmaceutiques, et enfin de garantir l'identification claire et non ambiguë des substances pharmaceutiques à l'échelle mondiale.

Notre corpus comprend au total 1 306 descriptions de mAbs, extraites spécifiquement des listes INN proposées numéros 10 à 129. Nous avons choisi de nous concentrer sur les versions anglaises de ces listes, car c'est la langue dominante dans la communication scientifique. Les descriptions dans les listes INN contiennent des motifs lexicaux prédictifs (comme les suffixes caractéristiques "mab, tug, bar..."), et présentent des structures récurrentes.

La sélection des données a fait l'objet d'un processus rigoureux incluant le reformatage du pdf, le filtrage des entrées non pertinentes, l'uniformisation des formats et le stockage comme mentionné dans (*Rapport_Stage_M2_DASSOU_SIKA*, 2022). Ce travail a permis de créer le premier corpus dédié à ce projet.

3.2. Annotation du corpus

L'annotation de notre corpus s'est déroulée selon une méthodologie en deux étapes :

3.2.1. Pré-annotation automatique

Nous avons d'abord procédé à une annotation automatique en exploitant les fonctionnalités de Pattern matching, une technique utilisée en TAL pour vérifier la présence de constituants d'un motif dans un texte. Cette technique nous a permis d'implémenter des règles linguistiques à l'aide des expressions régulières (regex) et des motifs syntaxiques pour identifier automatiquement des candidats d'entités potentielles dans notre corpus. Cette approche a permis d'accélérer considérablement le processus global d'annotation.

3.2.2. Correction et validation manuelles avec Label Studio

Les annotations issues de la phase de pré-annotation ont ensuite été corrigées et validées manuellement via la plateforme Label-Studio. Développée initialement par Heartex (renommée Human Signal en 2023), cette solution open-source s'est révélée particulièrement adaptée à notre tâche grâce à sa flexibilité et son interface utilisateur intuitive, facilitant le travail collaboratif. Cette étape a été réalisée en collaboration avec une experte du domaine afin d'assurer la qualité et la précision des annotations.

Notre corpus est intégralement annoté avec un ensemble de 18 labels (types d'entités) spécifiques aux anticorps monoclonaux, définis en cohérence avec les concepts utilisés au sein d'IMGT. Ces labels incluent: "RECEPT_ID", "SPECIFICITY", "MAB_SPECIES", "CHAIN_TYPE", "CHAIN_SPECIES", "DOMAIN_TYPE", "GENE", "ALLELE", "MUTATION",

“ALLOTYPES”, “CDR_IMGT”, “HINGE_REGION”, “CELL_LINE”, “SPECIFICITY_CLASS”, “BRIDGE”, “CONJUGATE”, “FUSED”, “PRODUCTION_SYSTEM” et “MOA”.

4. Revue des modèles entraînés

Pour pallier les limitations du système initial basé sur des règles, nous avons entraîné et affiné plusieurs modèles aux architectures différentes. Notre sélection s’est portée premièrement sur les modèles spécialement conçus pour traiter les documents scientifiques, puis les modèles NER spécialisés.

4.1. Les modèles scispaCy

ScispaCy est une bibliothèque Python construite sur spaCy et dédiée au traitement de textes scientifiques. Elle propose plusieurs modèles pré-entraînés que nous en avons choisi quatre pour les ré-entraîner sur notre tâche spécifique.

4.1.1. *en_ner_bionlp13cg_md*

Pré-entraîné sur le **corpus BIONLP13CG**, un jeu de données issu de la tâche BioNLP 2013, ce modèle est spécialisé en biologie cellulaire et génomique, et il reconnaît des entités comme telles que les cellules, organes, protéines, processus biologiques, ainsi que leurs **relations sémantiques**.

4.1.2. *en_ner_bc5cdr_md*

Pré-entraîné sur le **corpus BC5CDR** du défi BioCreative, ce modèle reconnaît des entités chimiques et des maladies, avec des annotations riches en entités biomédicales pertinentes pour la pharmacologie et la recherche médicale.

4.1.3. *en_core_sci_lg*

Ce modèle est entraîné sur des données issues de Semantic Scholar, ce qui lui confère une large couverture du vocabulaire scientifique. Il est enrichi par plus de 600 000 vecteurs de mots spécialisés, ce qui améliore sa capacité à comprendre le langage scientifique dans toute sa diversité.

4.1.4. *en_core_sci_scibert*

Basé sur l’architecture transformer SciBERT (allenai/scibert-base), ce modèle est pré-entraîné sur un corpus de publications scientifiques. Il est intégré dans un pipeline spaCy complet optimisé pour le domaine biomédical, avec un vocabulaire de près de 785 000 entrées, ce qui en fait un outil puissant pour notre tâche.

4.2. Le modèle BiLSTM-CRF

L’architecture BiLSTM-CRF (Bidirectional Long Short-Term Memory - Conditional Random Fields) est une approche neuronale profonde standard qui a démontré d’excellentes performances pour les tâches de séquençage d’étiquettes. Elle combine la capacité des réseaux LSTM bidirectionnels à capturer les dépendances contextuelles complexes dans les deux directions d’une séquence de mots avec la force des CRF pour prendre en compte les dépendances entre les étiquettes de sortie.

4.2.1. Architecture du modèle implémentée

Notre implémentation, développée avec TensorFlow/Keras et la bibliothèque tf2crf, suit une structure précise :

Une Couche d'entrée : qui prend des séquences d'indices (tokens) de n longueur (ex : 512 et pads).

Une Couche d'Embedding : qui récupère et transforme ces indices de tokens en vecteurs denses de n dimension.

Couche BiLSTM : une couche LSTM bidirectionnelle avec une taille de n unités. Elle retourne la séquence complète des états cachés et applique un dropout récurrent pour la régularisation.

Une Couche Dense : qui projette les sorties de la couche BiLSTM vers un espace de la dimension du nombre de tags (incluant le tag de padding).

Une Couche CRF : une couche CRF est ajoutée par-dessus de la couche dense. Cette couche apprend les contraintes entre les étiquettes de sortie et prédit la séquence d'étiquettes la plus probable.




Figure 2: Architecture principale du réseau (Lample et al., 2016b).

4.3. Le modèle GLiNER

GLiNER (Generalist model for NER) est un modèle spécifique pour NER qui se distingue par sa capacité à reconnaître des entités sans nécessiter de données d'entraînement spécifiques pour chaque type d'entité cible, ou en nécessitant très peu pour fine-tuning. Il est basé sur une architecture Transformer et est conçu pour être léger et efficace.

4.3.1. L'architecture du modèle GLiNER

Gliner adopte une architecture très flexible, basée sur l'**Entity Prompting**, et articulée autour des composants suivants :

Entrées du modèle : le modèle prend deux types d'entrée qui sont concaténés

- Une liste des types d'entités, qui sont représentées par des descriptions textuelles et encadrées par un token spécial [ENT].
- Une phrase d'entrée pour le texte à analyser.

Encodage bidirectionnel : L'ensemble d'entrée est encodé par un modèle de langage pré-entraîné bidirectionnels comme BERT ou DeBERTa, afin de produire des représentations vectorielles pour chaque token.

Traitement des types entités : Les embedding associés aux entités sont extraits à partir des représentations des tokens [ENT], puis passés à un réseau de neurones *feedforward* pour générer des représentations vectorielles des types d'entités.

Traitement des Span candidats : Les représentations vectorielles pour chaque token de la phrase d'entrées sont utilisée pour générer toutes les combinaisons possibles de Span. Chaque Span est encodé via une couche de représentation de Span qui est généralement un réseau BiLSTM.

Correspondances entre Span et entité : Un produit scalaire est calculé entre chaque représentation de Span et les vecteurs des types d'entité. Ensuite, une fonction sigmoïde est calculée pour déterminer un score de correspondance qui indique si « le Span est une entité de ce type ».

L'output : Une matrice de similarité **span-entity type** est générée indiquant la probabilité que ce span correspond à ce type d'entité.




Figure 3: L'architecture de GliNER (Zaratiana et al., 2023).

4.4. Le modèle BERT

BERT (**B**idirectional **E**ncoder **R**epresentations from **T**ransformers) est un modèle de langage pré-entraîné basé sur l'architecture Transformer, qui a démontré de très bonnes performances sur des tâches diverses de traitement automatique des langues. Sa capacité à comprendre les dépendances contextuelles bidirectionnelles en fait un outil particulièrement performant pour les tâches de NER, y compris dans des domaines spécialisés comme l'immunologie.

4.4.1. Architecture de BERT

Tokenisation : Les textes sont tout d'abord tokenisés en mot et sous-mot via un tokenizer (*WordPiece*) avec l'ajout de tokens spéciaux comme [CLS] et [SEP].

Couche d'embedding : Une fois les données tokenisées, BERT commence à les représenter en vecteur en convertissant chaque token de la séquence en vecteur via une combinaison de vecteurs de tokens, segments et de positions pour son entrée. Chaque token est représenté par la somme de ces trois vecteurs.




Figure 4: composition des embeddings d'entrée de BERT (Devlin et al., 2019).

Encodeur Transformer : La sortie de couche d'embedding est passée à une architecture Transformer composée de 12 couches de self-attention bidirectionnelle, chacun comprenant : Multi-head self-attention, Add & Norm, Feedforward network, Add & Norm. Cela permet à chaque token de s'informer du contexte global.

L'output : Un ensemble de vecteur est obtenu en sortie. Les vecteurs spéciaux [CLS] sont utilisés pour les tâches de classification. Les autres vecteurs peuvent être utilisés pour d'autres tâches, comme la NER.

Pour notre cas, un modèle BERT ré-entraîner consiste à représenter chaque token embedding et faire passer les séquences d'embedding à l'encodeur Transformers puis utiliser les vecteurs de sortie de l'ensembles des tokens non spéciaux pour faire des prédictions sur des étiquettes NER à l'aide d'une couche de classification dense spécifique à cela.




Figure 5:composant principal du BERT pré-entraîné et celui fine-tuné.

5. Conclusion

Nous avons présenté dans ce chapitre la méthodologie utilisée pour répondre à notre problématique. Nous avons d'abord évalué les limites du modèle IMGT-NER, puis explorer quatre approches modernes : les modèles scispaCy spécialisés en BioNER, l'architecture moderne de BiLSTM-CRF pour sa robustesse, GliNER pour sa flexibilité en few-shot learning, et BERT pour sa compréhension profonde du contexte des mots. Chaque modèle a été implémenté ou affiné sur notre jeu de données issues des listes INN, suivant un processus d'annotation semi-automatique. Les résultats comparatifs de ces modèles seront présentés et analysés en détail dans le prochain chapitre.

IV. Chapitre 3 : Analyse comparative des modèles

1. Introduction

Ce chapitre présente l'évaluation des modèles implémentés et affinés s au cours de ce stage. L'objectif est d'identifier les modèles qui performant le mieux sur notre tâche. Notre analyse repose sur trois axes :

- la description du jeu de données et des métriques d'évaluation ;
- une analyse comparative détaillée des résultats par modèle ;
- une synthèse globale des résultats mettant en lumière les points d'amélioration et les perspectives.

2. Description du jeu de données et méthodologie d'évaluation

Notre corpus, détaillé au chapitre 2, est constitué de 1306 descriptions issues des listes INN. Pour garantir la représentativité de toutes les entités dans l'ensemble de train (900 textes, 15 487 entités) et teste (406 textes, 6 357 entités), nous avons utilisé la méthode **Stratifying Multi-Label Data** (Sechidis et al., 2011) ou stratification des données multi-label en français, qui consiste à diviser un jeu de données en sous-ensembles de manière que la proportion de chaque étiquette soit préservée dans chaque sous-ensemble. Cela permet d'assurer que toutes les entités, y compris les plus rares, restent représentées dans chaque partie du jeu de données, ce qui est essentiel pour une évaluation fiable des modèles de classification multi-label.

Répartitions	Texte	%	Entités
Train	900	69%	15 487
Test	406	31%	6 357
Total	1306	100%	21 844

Tableau 2:Récapitulatif du jeu de données

3. Métriques d'évaluation utilisées

Les performances des différents modèles NER ont été évaluées selon les métriques standard utilisées en NER :

- **Précision** : Mesure l'exactitude des prédictions du modèle.

$$\text{Précision} = \frac{VP}{VP + FP}$$

VP : Vrais Positifs (entités correctement identifiées)

FP : Faux Positifs (entités incorrectement attribuées)

- **Rappel** : Évalue la capacité du modèle à retrouver toutes les entités pertinentes

$$\text{Rappel} = \frac{VP}{VP + FN}$$

FN : Faux Négatifs (entités manquées)

- **F1-score** : Combinaison harmonique de la précision et du rappel pour une mesure équilibrée

$$\mathbf{F1-score} = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

Le **F1-score** est crucial pour les jeux de données déséquilibrés.

4. Résultats

4.1. Résultats des modèles ScispaCy

Les modèles pré-entraînés de la bibliothèque ScispaCy ont été ré-entraînés et évalués sur notre jeu de données en conservant que les composants *tok2vec* et *ner* ou *transformer* et *ner* pour le modèle « *en_core_sci_scibert* », avec un tokenizer personnalisé.

4.1.1. Modèle '*en_ner_bionlp13cg_md*'

Le modèle *en_ner_bionlp13cg_md* a été ré-entraîné sur notre jeu de données avec les paramètres suivants : 20 itérations, une taille de batch de 4, et un tokenizer adapté aux nomenclatures d'anticorps.




Figure 6 : performances du modèle *en_ner_bionlp13cg_md*

Les évaluations montrent des performances globales stables, mais modestes, avec des scores identiques de 74% en précision, rappel et F1-score. Ces résultats représentent une légère baisse par rapport aux performances de base du modèle (78,1% de F1-score), principalement attribuable à la spécificité accrue de notre corpus contrastant avec le domaine pour lequel le modèle avait initialement.

L'analyse détaillée par type d'entité révèle des disparités significatives. Le modèle excelle pour les entités courtes et fréquentes comme '*CHAIN_TYPE*' et '*GENE*', mais montre des limitations pour les entités longues et rares comme '*PRODUCTION_SYSTEM*' et '*FUSED*'. Ces écarts s'expliquent par un manque de généralisation, un biais en faveur des entités courtes et un affinage insuffisant avec seulement 20 itérations sur des données très spécifiques.

4.1.2. Modèle '*en_ner_bc5cdr_md*'

Le modèle '*en_ner_bc5cdr_md*', initialement spécialisé dans la reconnaissance des entités chimiques et médicales, a été ré-entraîné sur notre corpus d'anticorps monoclonaux. Les résultats obtenus montrent des performances globales légèrement supérieures à celles du modèle '*en_ner_bionlp13cg_md*', avec une précision de 0.86 contre 0.74, mais un rappel plus faible à 0.835, ce qui se traduit par un F1-score de 0.857.

Figure 10 consists of two bar charts. The left chart, titled 'en_ner_bc5cdr_md -NER- Performances', shows the overall performance metrics: Precision (0.76), Recall (0.69), and F1 score (0.72). The right chart, titled 'Performances par entité', shows the performance per entity type for 14 classes: 'disease', 'drug', 'cell', 'cell_line', 'protein', 'protein_domain', 'cell_type', 'enzyme', 'biomarker', 'tissue', 'tissue_type', 'path', 'pathology', 'disease_progression', and 'cellular_component'. The legend indicates three series: 'Precision' (green), 'Recall' (orange), and 'F1 score' (blue).

Entity Type	Precision	Recall	F1 score
disease	0.95	0.94	0.94
drug	0.94	0.94	0.94
cell	0.94	0.94	0.94
cell_line	0.94	0.94	0.94
protein	0.94	0.94	0.94
protein_domain	0.94	0.94	0.94
cell_type	0.94	0.94	0.94
enzyme	0.94	0.94	0.94
biomarker	0.94	0.94	0.94
tissue	0.94	0.94	0.94
tissue_type	0.94	0.94	0.94
path	0.94	0.94	0.94
pathology	0.94	0.94	0.94
disease_progression	0.94	0.94	0.94
cellular_component	0.94	0.94	0.94

L'analyse par type d'entité, illustrée dans le graphique ci-dessus, confirme ces observations. Les entités courtes et fréquentes comme 'CHAIN_TYPE' obtiennent des scores satisfaisants, tandis que les entités complexes comme 'PRODUCTION_SYSTEM' obtiennent scores médiocres, enfin, les entités hybride (entre chimie et biologie) tel que 'CONJUGATE' obtiennent des résultats intermédiaires.

Le modèle '*en_core_sci_lg*' a montré des progrès significatifs après réentraînement. Les métriques globales révèlent une progression significative comparé au modèle de base : la précision est passée de 0.69 à 0.72 (+4.3%), le rappel de 0.68 à 0.72 (+5.9%), et le F1-score de 0.69 à 0.72 (+4.3%). Bien que ces scores restent légèrement inférieurs à ceux des autres modèles évalués, ce modèle se distingue par sa capacité à identifier les entités longues, comme on peut le voir dans le graphique d'analyse détaillée par type d'entité ci-dessous.



20

4.1.4. Modèle 'en_core_sci_scibert'

Ce modèle présente des performances contrastées. Il atteint une précision de 0.79 la plus élevée parmi les modèles ScispaCy, un rappel de 0.63 et un F1-score de 0.70. Ces scores révèlent la capacité du modèle à limiter les faux positifs, mais également sa difficulté à identifier des entités pertinentes. Cela s'explique par les forces et limites inhérentes à son architecture : d'une part, le modèle bénéficie d'un encodage contextuel avancé, ce qui lui confère une meilleure compréhension sémantique et une gestion efficace des ambiguïtés, d'autre part, il montre une faible sensibilité aux entités peu fréquentes ou longues comme on peut le voir dans les graphiques ci-dessous.




Figure 9: performances du modèle en_core_sci_scibert

4.2. Résultats du modèle GLiNER

Ce modèle présente des résultats particulièrement convaincants qui en font une solution de premier plan pour notre tâche. Avec une précision de 0.8041%, un rappel de 0.8645% et un F1-score de 0.8332%. Son architecture flexible basée sur le Entity-prompting lui permet d'atteindre ces scores tout en conservant une grande adaptabilité aux différents types d'entités, des plus courantes aux plus spécialisées. Cependant, certaines entités complexes comme 'CONJUGATE', 'SPECIFICITY' continuent de poser des défis, révélant les limites actuelles du modèle face aux entités longues même si ses performances restent très satisfaisantes. Voir graphiques des performances ci-dessous.




Figure 10: performances du modèle GLiNER

4.3. Résultats du modèle BiLSTM-CRF

Ce modèle a obtenu d'excellents résultats avec un F1-score global de 0.92%, démontrant un parfait équilibre entre la précision 0.92% et le rappel 0.91%. Cette performance s'explique par sa double architecture : les couches BiLSTM capturent efficacement les dépendances contextuelles, tandis que le CRF optimise la cohérence des séquences d'étiquettes. L'analyse détaillée par type d'entité montre aussi une grande cohérence des résultats. Ci-joint, le graphique les performances du modèle.




Figure 11: performances du modèle BiLSTM-CRF

4.4. Résultats du modèle BERT

Basé sur l'architecture "bert-base-uncased" et affiné sur notre corpus, BERT démontre des performances remarquables lors de son évaluation.




Figure 12: des performances du modèle BERT

Avec un F1-score élevé de 0.84%, indiquant son efficacité pour cette tâche. Son rappel de 0.88,39% est particulièrement important, indiquant qu'il est capable de reconnaître une grande partie des entités pertinentes. Sa précision de 0.80,12% reste solide malgré les complexités de la tâche. La perte de validation relativement faible (0.2552) montre que le modèle généralise bien sur des données d'entraînement et sans sur-apprentissage.

Ces résultats soulignent l'avantage des représentations contextuelles de BERT pour capturer les nuances des mots.

4.5. Synthèse globale des résultats

Afin de mieux appréhender les forces et faiblesses de chaque modèle, nous présentons dans ce qui suit une comparaison directe de leurs performances sur notre ensemble de test. Les résultats

sont synthétisés dans le tableau ci-dessous, suivis d'une analyse comparative. Le tableau regroupe les principaux scores en Précision, Rappel et F1-Score obtenus par chaque modèle sur l'ensemble de test de 406 descriptions d'anticorps monoclonaux.

Modèle	Précision	Rappel	F1-score
en_ner_bionlp13cg_md	0.73,5%	0.72,1%	0.72,7%
en_ner_bc5cdr_md	0.75,9%	0.68,6%	0.72,1%
en_core_sci_lg	0.72,0%	0.71,8%	0.71,9%
en_core_sci_scibert	0.78,5 %	0.63,8%	0.69,9 %
BiLSTM-CRF	0.92,45%	0.92,11%	0.92,21%
GLiNER	0.80,41%	0.86,45%	0.83,32%
BERT	0.80,12%	0.88,39%	0.84,05 %

Tableau 3: Tableau récapitulatif des performances

4.5.1. Comparaison des performances

Notre évaluation comparative révèle des écarts significatifs entre les différentes architectures. Le modèle *BiLSTM-CRF* domine avec un F1-score de 0.92,21%, combinant précision (0.92,45%) et rappel (0.92,11%) équilibrés. Les architectures Transformer (**BERT** F1=0.84,05%, **GLiNER** F1=0.83,32%) offrent des alternatives compétitives, surpassant nettement les modèles **ScispaCy** entre (F1=0.69,9% à 0.72,7%). Deux tendances émergent :

1. La **spécificité de l'entraînement** prime : BiLSTM-CRF, entraîné spécifiquement, surpasse les modèles pré-entraînés.
2. Le **compromis précision/rappel** varie selon les architectures (BERT favorise le rappel, SciBERT la précision). Voir aussi le graphique de performance par métrique




Figure 13: graphique de performance par métrique

4.5.2. *Adéquation à la tâche et perspectives*

Le BiLSTM-CRF s'impose comme solution optimale pour notre corpus, mais trois limites ouvrent des pistes d'amélioration :

Volume de données : l'extension du corpus (actuellement 1 306 descriptions) renforcerait la couverture des entités rares

Complexité des entités : les architectures actuelles peinent avec les entités imbriquées/discontinues

Optimisation : Une analyse d'erreurs ciblée (par type/longueur d'entité) guiderait les ajustements

5. Conclusion

Ce chapitre a montré la supériorité des modèles de Deep Learning spécialisées dans l'extraction d'entités. Le modèle BiLSTM-CRF s'impose comme la solution la plus performante grâce à une architecture adaptée et un entraînement ciblé. Les limites identifiées, telles que la taille du corpus ou la complexité de certaines entités, dessinent clairement les axes d'amélioration à explorer.

V. Chapitre 4 : Développement de l'interface Utilisateur et Déploiement

1. Introduction

Dans ce chapitre, nous nous concentrons sur la valorisation de ces travaux à travers la création d'une application interactive. L'objectif principal est de fournir un outil pratique permettant d'effectuer l'inférence des modèles NER entraînés sur de nouvelles descriptions d'anticorps afin d'identifier et de visualiser les entités reconnues de manière intuitive.

La création d'une interface utilisateur (UI) permet une exploration interactive des résultats par n'importe quel utilisateur, qu'il soit expert ou non-expert, et constitue un prototype fonctionnel qui pourrait être intégré dans des flux de travail plus larges d'analyse de documents biomédicaux. Pour ce faire, nous avons choisi *Streamlit*, un framework Python très utilisé, reconnu aussi pour sa simplicité et sa rapidité de développement pour les applications de Machine Learning.

2. Fonctionnalités de l'interface utilisateur

L'application développée propose un ensemble de fonctionnalités conçues pour faciliter l'exploration et l'utilisation des modèles NER. Nous avons donc implémenté plusieurs sections: la sélection du modèle, la saisie du texte, le filtrage des types d'entités ainsi que les informations sur les modèles NER chargés. Une fois un modèle chargé et lancé sur le texte saisi, l'utilisateur peut visualiser et télécharger le résultat.

Sélection du modèle NER

L'utilisateur peut choisir parmi plusieurs modèles NER disponibles via un menu déroulant situé dans la barre latérale.

Saisie et sélection du texte à analyser

L'application offre deux manières de fournir le texte à analyser :

Saisie libre : avec une zone de texte permet à l'utilisateur de coller ou de rédiger directement la description du mAb qu'il souhaite analyser.

Exemples prédéfinis : avec un menu déroulant propose une liste d'exemples de textes. Si l'utilisateur choisit un exemple, le contenu de la zone de texte est automatiquement mis à jour avec le texte de l'exemple sélectionné.

Filtrage des types d'entités

Pour permettre à l'utilisateur de se concentrer sur des types d'entités spécifiques, une sélection est possible et est disponible dans la barre latérale. Il permet de sélectionner les types d'entités qui seront affichés dans les résultats (texte surligné, statistiques et tableaux). Par défaut, tous les types sont sélectionnés.

Informations sur le modèle chargé

Des informations contextuelles sur le modèle actuellement sélectionné et chargé sont affichées

dans la barre latérale. Cela peut inclure une brève description du modèle, la taille de son vocabulaire, le nombre d'étiquettes, ou les noms, la version et le pipeline.

Lancement de l'analyse et traitement NER

Une fois le texte saisi et le modèle sélectionné, l'utilisateur clique sur le bouton "Identify Entities" pour lancer l'analyse. Si le champ de texte est vide, un avertissement est affiché. Sinon, le processus suivant est enclenché :

- **Indication de progression** : un message d'information est affiché.
- **Pré-traitement** : le texte d'entrée est d'abord pré-traité par le pipeline de pré-traitement correspondant au modèle sélectionné. Cette étape peut inclure la tokenisation, la conversion en identifiants numériques, etc., en fonction des exigences du modèle.
- **Inférence du modèle** : les données pré-traitées sont ensuite passées au modèle chargé pour obtenir les prédictions.
- **Post-traitement** : les prédictions brutes du modèle sont ensuite transformées en une liste structurée d'entités (contenant le texte de l'entité, son type, et ses positions de début et de fin) par la méthode. Cette étape utilise également les données issues du prétraitement et le texte original pour reconstruire correctement les entités.

Visualisation des résultats

Si l'analyse s'est déroulée avec succès, les résultats sont présentés de plusieurs manières :

- **Statistiques sur les entités** : le nombre total d'entités affichées (en tenant compte des filtres actifs) et le type d'entité le plus fréquent et son nombre d'occurrences sont également affichés.
- **Entités identifiées surlignées dans le texte** avec des couleurs spécifiques à leur type.
- **Liste des entités extraites** : un tableau présente la liste des entités extraites, affichant le texte de l'entité et son type. Ce tableau est également filtré en fonction des types d'entités sélectionnés par l'utilisateur.

Export des entités extraites

Pour permettre une analyse plus approfondie ou une réutilisation des résultats, l'application offre une fonctionnalité d'exportation des entités identifiées (et filtrées) au format CSV.

3. Déploiement de l'application

Une fois l'interface utilisateur développée et testée localement, l'étape suivante consiste à la déployer en local sur le serveur d'IMGT pour la rendre accessible à d'autres utilisateurs (l'équipe IMGT).

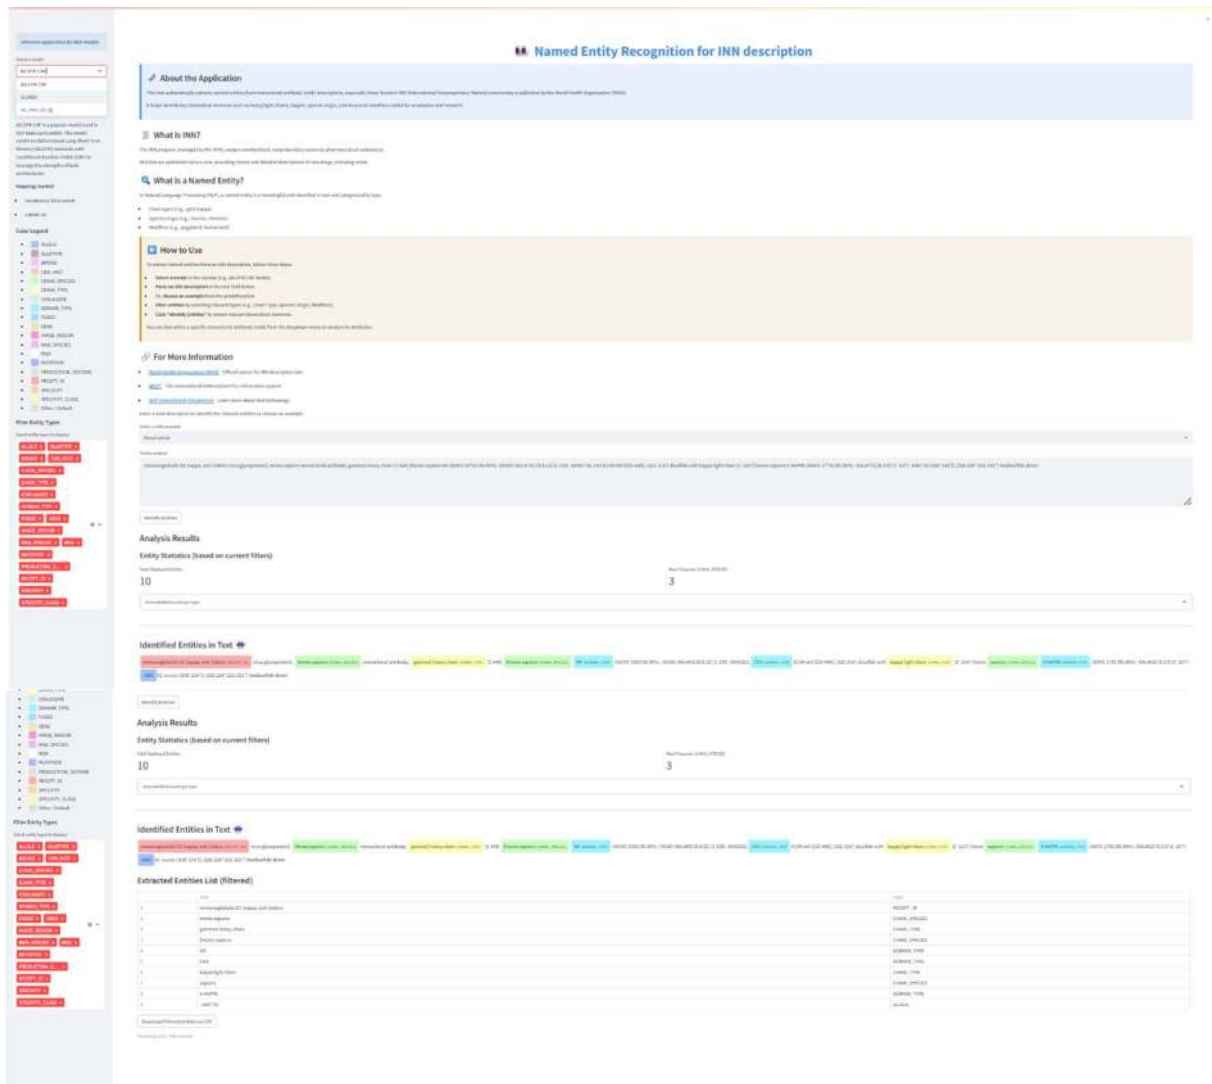


Figure 14: l'interface d'IMGT-NER

4. Conclusion

Ce chapitre a détaillé la conception, le développement et le déploiement d'une interface utilisateur interactive pour l'inférence de nos modèles NER. L'utilisation de Streamlit comme Framework de développement a permis de créer rapidement une application web fonctionnelle, offrant une expérience utilisateur intuitive pour tester et visualiser les performances des différents modèles.

En perspective, cette interface pourrait être enrichie par de nouvelles fonctionnalités, telles que la possibilité de comparer les résultats de plusieurs modèles sur le même texte, l'intégration de métriques de performance en temps réel si des données de test annotées sont fournies par l'utilisateur, ou encore une gestion plus fine des types d'entités pour les modèles comme GLiNER directement depuis l'interface. Néanmoins, en l'état, l'application remplit son rôle de démonstrateur et d'outil d'inférence pratique, pont entre la recherche en TAL et son application concrète.

VI. CONCLUSION

Ce stage a abouti à la mise en place d'une solution complètement basée sur l'apprentissage profond, répondant aux limitations d'une première solution basée sur des règles.

La mise en place d'un corpus de 1306 descriptions (39 991 entités, 19 catégories) comble un vide critique dans le domaine de l'immunogénétique, où aucun jeu de données spécialisé pour les anticorps monoclonaux n'existait auparavant. Cette ressource annotée manuellement avec 18 types d'entités spécifiques (cibles thérapeutiques, mécanismes d'action, etc.) constitue le premier corpus de référence pour la NER dans ce domaine très spécialisé.

L'évaluation des modèles montre que le modèle BiLSTM-Crf a obtenu la meilleure performance avec un F1-Score de 0.92% surpassant BERT 0.84% et GliNER 0.83%. Les modèles de scispaCy ont obtenu des performances inférieures (entre 0.69% ET 0.72% de F1-score)

Pour valoriser ce travail et faciliter son utilisation par les chercheurs et chercheuses, une interface utilisateur interactive a été développée avec Streamlit. Cette application permet de sélectionner dynamiquement le modèle NER à utiliser, de saisir ou sélectionner le texte à analyser, et de visualiser les entités reconnues avec un système de surlignage coloré. Des fonctionnalités de filtrage par type d'entité et d'export des résultats au format CSV ont également été implémentées.

Malgré ces résultats, il y a des points à améliorer. Bien que le corpus annoté soit considérable pour le domaine, il reste limité vis-à-vis des autres domaines connexes et pourrait être augmenté pour couvrir plus descriptions provenant des listes INN et d'autres sources de données. De plus, l'approche actuelle se concentre uniquement sur l'extraction d'entités et ne traite pas encore les relations entre ces entités (entity linking), qui seraient essentielles pour une intégration dans le graphe de connaissance IMGT/mAb-KG. Enfin, les performances des modèles, bien que excellentes, restent à améliorer notamment pour les entités rares et les entités longues. Ces limitations ouvrent la voie à plusieurs perspectives.

VII. Références

- Borkowski, C., & Watson, T. J. (1967). An Experimental System for Automatic Recognition of Personal Titles and Personal Names in Newspaper Texts. *COLING 1967 Volume 1: Conference Internationale Sur Le Traitement Automatique Des Langues*. COLING 1967. <https://aclanthology.org/C67-1023/>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* (No. arXiv:1810.04805). arXiv. <https://doi.org/10.48550/arXiv.1810.04805>
- Eftimov, T., Koroušić Seljak, B., & Korošec, P. (2017). A rule-based named-entity recognition method for knowledge extraction of evidence-based dietary recommendations. *PLOS ONE*, 12(6), e0179488. <https://doi.org/10.1371/journal.pone.0179488>
- Keraghel, I., Morbieu, S., & Nadif, M. (2024). *Recent Advances in Named Entity Recognition : A Comprehensive Survey and Comparative Study* (No. arXiv:2401.10825). arXiv. <https://doi.org/10.48550/arXiv.2401.10825>
- Lafferty, J., McCallum, A., Pereira, F., & Street, H. (2001). *Conditional Random Fields : Probabilistic Models for Segmenting and Labeling Sequence Data*. In Proceedings of the Eighteenth International Conference on Machine Learning (ICML 2001), 282–289.
- Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K., & Dyer, C. (2016a). Neural Architectures for Named Entity Recognition. In K. Knight, A. Nenkova, & O. Rambow (Éds.), *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (p. 260-270). Association for Computational Linguistics. <https://doi.org/10.18653/v1/N16-1030>
- Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K., & Dyer, C. (2016b). Neural Architectures for Named Entity Recognition. In K. Knight, A. Nenkova, & O. Rambow

- (Éds.), *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (p. 260-270). Association for Computational Linguistics. <https://doi.org/10.18653/v1/N16-1030>
- Rapport_Stage_M2_DASSOU_SIKA*. (s. d.), 2022.
- Sechidis, K., Tsoumakas, G., & Vlahavas, I. (2011). On the Stratification of Multi-label Data. In D. Gunopulos, T. Hofmann, D. Malerba, & M. Vazirgiannis (Éds.), *Machine Learning and Knowledge Discovery in Databases* (p. 145-158). Springer. https://doi.org/10.1007/978-3-642-23808-6_10
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). *Attention is All you Need*. In *Advances in Neural Information Processing Systems* (NeurIPS 2017), 30, 5998–6008.
- Zaratiana, U., Tomeh, N., Holat, P., & Charnois, T. (2023). *GLiNER: Generalist Model for Named Entity Recognition using Bidirectional Transformer* (No. arXiv:2311.08526). arXiv. <https://doi.org/10.48550/arXiv.2311.08526>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* (No. arXiv:1810.04805). arXiv. <https://doi.org/10.48550/arXiv.1810.04805>
- Huang, Z., Xu, W., & Yu, K. (2015). *Bidirectional LSTM-CRF Models for Sequence Tagging* (No. arXiv:1508.01991). arXiv. <https://doi.org/10.48550/arXiv.1508.01991>
- Neumann, M., King, D., Beltagy, I., & Ammar, W. (2019). ScispaCy : Fast and Robust Models for Biomedical Natural Language Processing. *Proceedings of the 18th BioNLP Workshop and Shared Task*, 319-327. <https://doi.org/10.18653/v1/W19-5034>

VIII. Liste des figures

Figure 1: la structure d'un anticorps	7
Figure 2: Architecture principale du réseau (Lample et al., 2016b).	15
Figure 3: L'architecture de GliNER (Zaratiana et al., 2023).	16
Figure 4: composition des embeddings d'entrée de BERT (Devlin et al., 2019).....	17
Figure 5: composant principal du BERT pré-entraîné et celui fine-tuné.	17
Figure 6: : performances du modèle en_ner_bionlp13cg_md.....	19
Figure 7: performances du modèle en_ner_bc5cdr_md.....	20
Figure 8: performances du modèle en_core_sci_lg.....	20
Figure 9: performances du modèle en_core_sci_scibert.....	21
Figure 10: performances du modèle GliNER.....	21
Figure 11: performances du modèle BiLSTM-CRF	22
Figure 12: des performances du modèle BERT	22
Figure 14: graphique de performance par métrique	23
Figure 15: l'interface d'IMGT-NER	27

IX. Liste des tableaux

Tableau 1: Résultat d'évaluation d'IMGT-NER.....	12
Tableau 2: Récapitulatif du jeu de données.....	18
Tableau 3: Tableau récapitulatif des performances.....	23